AGENCE-MUSICIENS · SEMAINE 3

L'intelligence artificielle dans le produit

Fonctions IA, erreurs visibles, coûts et retour d'expérience · 19 octobre 2026

Côté serveur seulement

Claude est appelé depuis le serveur (`src/lib/ia.ts`) ; la clé reste dans les variables d'environnement de Vercel.

Réservé à l'agent

Les droits sont vérifiés côté serveur : un musicien est renvoyé, une route d'API répond 403.

L'agent valide toujours

Aucune réponse du modèle ne déclenche d'action : tout est relu, corrigé, enregistré ou copié par l'agent.

1 Les fonctions IA et les erreurs visibles

Pour chaque fonction : ce qu'elle fait, et ce que l'agent voit lorsque le modèle se trompe ou échoue.

FONCTION	CE QU'ELLE FAIT	QUAND LE MODÈLE SE TROMPE, L'AGENT VOIT…
Lire un courrier Courriers	Remplit expéditeur, signataire, date, référence, montant et type de dossier, dans un format imposé (sortie structurée, revérifiée à l'arrivée). Pour chaque champ, le modèle cite l'extrait exact du courrier.	absent du courrier si l'information n'y figure pas (courrier sans montant, sans date précise). à relire si l'extrait cité est introuvable, ou si la date ou le montant n'y sont pas écrits : le code le vérifie, c'est là qu'une invention se voit (*« l'IA a peut-être inventé »*). *« Réponse de l'IA illisible : rien n'est enregistré »* si la réponse sort du format. Tout reste modifiable avant l'enregistrement.
Classer même appel	Une catégorie parmi quatre (annulation, changement, question, autre), avec une phrase de raison.	La catégorie proposée, modifiable avant l'enregistrement.
Résumer même appel	Une phrase de résumé.	proposé par l'IA, à relire ; modifiable avant l'enregistrement.
Brouillon de réponse fiche courrier	Une réponse courtoise, écrite en streaming, qui ne doit rien inventer ni promettre et demande ce qui manque.	rédigé par l'IA, à relire *« il ne doit rien promettre que l'agence n'a pas décidé »*. Le texte n'est ni enregistré ni envoyé : l'agent le corrige, le copie ou le jette.
Question sur les documents Documents	Recherche les 5 pages les plus proches parmi les 20 documents indexés (embeddings Voyage AI, pgvector), puis répond en streaming en citant ses sources.	Les pages citées sous la réponse, avec la phrase citée ; la liste des 20 documents permet de vérifier une page. Aucune source ne peut être inventée : l'API ne cite que les pages fournies. Question hors sujet : *« aucune source citée »*. Les étapes s'affichent pendant l'appel.

FONCTION	CE QU'ELLE FAIT	QUAND LE MODÈLE SE TROMPE, L'AGENT VOIT…
Analyse de la nuit Journal des imports, récap	Trois à cinq phrases sur ce que le flux a apporté, pour la dernière nuit importée à chaque passage.	Analyse (IA, à relire) ; en cas d'échec, *« indisponible (raison) »*, et la nuit est importée quand même. Un message du flux qui contient une consigne reste une donnée : il est balisé et ne peut pas sortir de sa balise.

> Lorsque le plafond mensuel ou la limite du jour sont atteints, l'agent lit la raison (*« Plafond de 5 $ atteint ce mois-ci »*, *« Limite de 30 appels à l'IA par jour atteinte »*) et aucun appel n'est fait.

2 Coût par appel et par mois

Toutes les fonctions utilisent **Claude Haiku 5.5** (0,10 $ par million de jetons en entrée, 0,50 $ en sortie). **Sonnet 5.5** (2 $ / 10 $) peut être choisi par l'agent pour un courrier complexe. Les embeddings sont calculés par **Voyage AI**, sur son offre gratuite.

FONCTION	COÛT PAR APPEL (ESTIMÉ)
Lire, classer et résumer un courrier (Haiku)	≈ 0,001 $
Lire un courrier avec Sonnet	≈ 0,01 $
Question sur les documents (recherche Voyage comprise, gratuite)	≈ 0,001 $
Brouillon de réponse	≈ 0,0005 $
Analyse de la nuit	≈ 0,0005 $
Indexation des 20 documents (50 pages, une fois ; une page inchangée n'est jamais recalculée)	0 $

≈ 0,15 $
par mois pour une agence : 30 analyses de nuit, 50 courriers, 100 questions, 50 brouillons

5 $
plafond mensuel dans le produit, doublé d'un plafond de dépense dans la console Anthropic

0 €
d'infrastructure : offres gratuites de Vercel, Neon, Resend, Sentry, UptimeRobot et Voyage

Garde-fous. 30 appels par utilisateur et par jour ; courrier de 10 000 caractères et PDF de 2 Mo au plus ; question de 500 caractères au plus ; au-delà du plafond mensuel, plus aucun appel et une alerte envoyée par Sentry.

Les coûts par appel sont estimés d'après la taille des appels. Les chiffres réels (coût moyen par appel, total du mois) sont relevés par la page `/couts` du produit, qui enregistre chaque appel avec ses jetons.

3 Un moment où l'IA a tourné en rond

Contexte. Le 19 octobre, la prévisualisation de la branche `brouillon` ne se construisait pas. Le journal de Vercel indiquait : `Please provide required params for Postgres driver: url: undefined`. L'adresse de la base de données de prévisualisation était absente.

1. **Première hypothèse : un retard.**
   La même panne avait touché la branche `questions`, puis disparu au second essai, sans que la cause soit recherchée. L'IA a supposé que, pour une branche neuve, la construction démarrait avant que Neon ait fourni l'adresse de la nouvelle base, et a proposé de relancer le déploiement.

2. **Deuxième essai : même échec.**
   Le déploiement relancé sans cache a échoué de la même façon. Relancer encore, par exemple avec un commit vide, aurait pu se répéter indéfiniment et aurait masqué la cause.

3. **Sortie : arrêter de relancer et lire.**
   Une adresse toujours absente après un second essai ne relève pas d'un retard : la base n'avait jamais été créée. Cause identifiée : l'offre gratuite de Neon limite le nombre de branches de base, et chaque fonctionnalité en avait créé une sans qu'elle soit supprimée après la fusion. Les branches des fonctionnalités déjà fusionnées ont été supprimées dans Neon, la branche principale conservée, et la construction suivante a réussi.

> **Enseignement.** La panne de la branche `questions` était le même problème, laissé de côté parce qu'un second essai avait réussi. Deux relances sans progrès signalent qu'il faut s'arrêter et lire le journal, non relancer une troisième fois. Le remède, faire le ménage dans Neon après chaque fusion, est consigné dans le suivi du projet.